HACKATHON INE 2026

Hackea la participación: Datos que construyen democracia

DOCUMENTO TÉCNICO

Segmentación de perfiles ciudadanos de participación electoral en México

Datos históricos 2009–2024

Reto 1
Perfiles ciudadanos de participación

EQUIPO

Bugs Bunny

INTEGRANTES

Aguilar Lara Ericka
Bautista Reyes Sofía
Cruz Basilio Ximena Carolina
Jardón Marín Rodrigo

Ciudad de México, México

Octubre de 2026

Resumen

Este proyecto identifica perfiles ciudadanos de participación electoral mediante los Conteos Censales de Participación Ciudadana (CCPC) del Instituto Nacional Electoral (INE) correspondientes a 2009, 2012, 2015, 2018, 2021 y 2024 [1, 2]. Se homologaron las seis bases y se construyó una unidad común definida por entidad federativa, grupo de edad, sexo y tipo de sección. La integración produjo 2,546 unidades distintas; 2,496 contaron con información completa en las seis elecciones y constituyeron la base comparable. Sobre sus seis tasas históricas de participación estandarizadas se evaluaron soluciones K-means con cuatro, cinco y seis conglomerados. La solución de cuatro perfiles obtuvo el mayor coeficiente de silueta entre las alternativas y mostró estabilidad ante la exclusión temporal de grupos pequeños. Los perfiles se distinguen principalmente por niveles persistentes de participación y presentan diferencias en edad, sexo y tipo de sección. Con base en estos resultados se proponen estrategias institucionales diferenciadas de información y accesibilidad electoral.

1. Contexto, problema y objetivos

La plataforma de los CCPC permite consultar participación y abstencionismo por variables sociodemográficas y territoriales, incluyendo sexo, edad, entidad y tipo de sección [1, 2]. Analizar únicamente promedios generales puede ocultar diferencias importantes entre grupos, mientras que la disponibilidad de seis procesos electorales permite observar persistencia y cambio en el tiempo.

El proyecto responde al Reto 1 del Hackathon del INE, orientado a construir de cuatro a seis perfiles ciudadanos y proponer estrategias diferenciadas [3]. La pregunta de análisis fue: **¿qué perfiles ciudadanos pueden identificarse a partir de las características sociodemográficas, territoriales y del comportamiento histórico de participación electoral entre 2009 y 2024?**

El objetivo general fue identificar y caracterizar perfiles de participación mediante técnicas de segmentación sobre datos agregados. Los objetivos específicos fueron:

1. Integrar y homologar las seis elecciones.
2. Construir indicadores comparables.
3. Analizar el comportamiento histórico.
4. Evaluar soluciones de cuatro a seis conglomerados.
5. Caracterizar los perfiles para plantear estrategias institucionales diferenciadas.

2. Datos y metodología

2.1. Fuente y unidad de análisis

Se utilizaron las bases oficiales de los CCPC publicadas por el INE [1]. Los datos son agregados y no contienen información personal identificable. La unidad de análisis se definió como:

$$\textit{Entidad} + \textit{Grupo de edad} + \textit{Sexo} + \textit{Tipo de sección}.$$

Las edades se agruparon en 13 intervalos: 18–19, 20–24, 25–29, 30–34, 35–39, 40–44, 45–49, 50–54, 55–59, 60–64, 65–69, 70–74 y 75 años o más. Para cada combinación se sumaron los conteos de lista nominal (LN), sí votó (SV), no votó (NV) y no especificado (NS).

La participación y la abstención se calcularon después de la agregación:

$$\textit{Participación} = \frac{SV}{SV + NV} \times 100, \qquad \textit{Abstención} = \frac{NV}{SV + NV} \times 100.$$

Los registros NS se conservaron como indicador de calidad, pero se excluyeron del denominador de estas dos tasas. También se marcó como `GRUPO_PEQUENO` toda unidad con $SV + NV < 100$; este umbral se utilizó únicamente para análisis de sensibilidad y no corresponde a un criterio oficial del INE.

2.2. Preparación, validación e integración histórica

Para cada año se verificó que el archivo correspondiera a la elección esperada, que incluyera las 32 entidades y que cumpliera $LN = SV+NV+NS$. También se comprobó que los totales nacionales fueran idénticos antes y después de la agregación.

Cuadro 1: Resumen de validación de las bases procesadas

Año	Entidades	Grupos	Inconsistencias	Grupos pequeños
2009	32	2496	0	26
2012	32	2496	0	26
2015	32	2496	0	26
2018	32	2496	0	24
2021	32	2496	0	26
2024	32	2546	0	61

En 2009, 2012, 2015, 2018 y 2021 se obtuvieron 2,496 unidades después de la agregación; en 2024 se obtuvieron 2,546 debido a la presencia adicional de registros de sexo no bina-

rio. En los seis años se conservaron exactamente los totales de LN, SV, NV y NS, y no se detectaron inconsistencias en la relación $LN = SV + NV + NS$. Esta verificación fue importante para asegurar que la reducción de millones de registros originales a unidades analíticas no modificara los conteos de origen.

También se calculó la participación nacional a partir de los conteos totales como comprobación descriptiva, diferenciándola del promedio simple de las unidades. Esta distinción evita interpretar como tasa nacional un promedio en el que cada combinación demográfica y territorial tiene el mismo peso, independientemente de su tamaño poblacional.

Antes de integrar la serie se homologó *Distrito Federal* como *Ciudad de México*. La unión produjo 2,546 unidades, de las cuales 2,496 contaron con información en las seis elecciones (98.04 %). Las 50 restantes corresponden a la categoría de sexo no binario disponible en 2024; se conservaron en la base maestra, pero no se imputaron valores históricos inexistentes.

La base comparable quedó formada por $32 \times 13 \times 2 \times 3 = 2496$ unidades. Para cada una se conservaron las tasas `PART_2009`, `PART_2012`, `PART_2015`, `PART_2018`, `PART_2021` y `PART_2024`.

Como diagnóstico de cobertura se contó el número de elecciones disponibles para cada combinación. Después de homologar Ciudad de México, únicamente se observaron dos patrones: 2,496 unidades con las seis elecciones y 50 unidades presentes sólo en 2024. No se detectaron duplicados de llave, valores faltantes dentro de la base comparable ni tasas fuera del intervalo 0–100.

Además de las seis tasas se calcularon promedio histórico, desviación estándar, cambio 2009–2024 y tendencia lineal. Estos indicadores se reservaron principalmente para interpretación, ya que incorporarlos simultáneamente al modelo habría duplicado información derivada de las mismas tasas históricas.

2.3. Segmentación

Se utilizó K-means como técnica de aprendizaje no supervisado. Antes del agrupamiento, las seis tasas históricas se estandarizaron para que cada elección contribuyera en una escala comparable. Edad, sexo, entidad y tipo de sección no se utilizaron para formar los clusters; se reservaron para caracterizarlos posteriormente. Esta separación permite que los perfiles emerjan del comportamiento histórico de participación y no de una codificación arbitraria de variables categóricas.

Se evaluaron $k \in \{4, 5, 6\}$ y se compararon coeficiente de silueta, inercia, tamaños de cluster e interpretabilidad. El coeficiente de silueta se utilizó como apoyo para valorar cohesión y separación entre conglomerados [4, 5].

Como prueba adicional de robustez se repitió el clustering después de excluir temporalmente las unidades que presentaron al menos un año con menos de 100 registros determinados. La similitud entre las asignaciones se evaluó mediante el índice de Rand ajustado (ARI). De esta forma se comprobó si los grupos pequeños estaban alterando de manera importante la estructura general de la segmentación.

2.4. Reproducibilidad

El procesamiento se desarrolló en Python mediante notebooks de Google Colab. Cada elección cuenta con un notebook independiente de exploración y validación; posteriormente se construyeron notebooks específicos para integración histórica, análisis exploratorio, clustering y caracterización. El repositorio del proyecto separa datos procesados, tablas de compatibilidad, notebooks, resultados de perfiles, gráficas y documentación. Esta organización facilita la revisión del análisis. Las bases originales se obtienen del portal del INE; los notebooks utilizan rutas de Google Colab que deben adaptarse para reproducirlos.

3. Análisis exploratorio histórico

Antes del clustering se revisó la distribución de las tasas de participación en las 2,496 unidades comparables. Los promedios simples por unidad no representan tasas nacionales, pero permiten comparar el nivel relativo de los grupos entre elecciones.

Cuadro 2: Resumen de participación por elección en las unidades comparables

Elección	Promedio simple	Desv. estándar	Mediana
2009	48.02 %	13.32	48.38 %
2012	64.43 %	10.91	65.77 %
2015	52.30 %	14.68	53.00 %
2018	63.80 %	11.06	64.60 %
2021	55.83 %	13.36	56.76 %
2024	61.27 %	12.71	62.39 %

Las correlaciones entre elecciones fueron positivas y relativamente altas, con valores aproximados entre 0.69 y 0.91. Las asociaciones más altas se observaron entre 2018 y 2024 (0.91), 2012 y 2018 (0.91), y 2021 y 2024 (0.90). Esto sugiere persistencia en la posición relativa de muchos grupos, aunque existe suficiente variación para justificar el análisis conjunto de las seis elecciones.

El análisis descriptivo también mostró diferencias claras por características sociodemográficas. El promedio histórico de las unidades de mujeres fue 60.59 %, frente a 54.63 % en hombres. Por tipo de sección, el promedio fue 60.41 % en rural, 56.56 % en mixta y 55.86 % en urbana.

Por edad, los promedios más bajos se observaron en 20–24 años (45.05 %) y 25–29 (44.38 %). A partir de 30–34 años se observó un incremento gradual: 48.90 % en 30–34, 53.93 % en 35–39, 57.97 % en 40–44, 61.07 % en 45–49 y 63.56 % en 50–54. El máximo se alcanzó en 65–69 años (68.23 %), seguido por una disminución en 70–74 y una caída más marcada en 75+. Estas variables se reservaron para caracterizar los clusters y no se incorporaron directamente al K-means.

También se revisaron las 26 unidades que presentaron al menos un año clasificado como grupo pequeño. Su participación histórica promedio fue 47.84 %, frente a 57.71 % en las demás unidades. Dada esta diferencia, se mantuvieron en el modelo principal y su efecto se evaluó mediante la prueba de sensibilidad descrita anteriormente.

4. Resultados

4.1. Selección del número de perfiles

Cuadro 3: Comparación de soluciones K-means

k	**Silueta**	**Inercia**	**Cluster menor**	**Porcentaje mínimo**
4	0.2895	3629.07	362	14.50 %
5	0.2478	3211.41	279	11.18 %
6	0.2531	2899.17	261	10.46 %

La solución con cuatro conglomerados presentó el mayor coeficiente de silueta. Además, sus grupos mantuvieron tamaños suficientes para su interpretación. Al excluir temporalmente las 26 unidades que presentaron al menos un año con menos de 100 registros determinados, la silueta pasó de 0.2895 a 0.2893 y el índice de Rand ajustado fue 0.9157, por lo que la estructura general se mantuvo muy similar. Se adoptó, por tanto, una solución final de cuatro perfiles.

Los centroides muestran que los cuatro perfiles comparten una forma temporal semejante, pero se distinguen por niveles persistentemente diferentes de participación. Esto indica que el modelo identifica principalmente perfiles históricos de nivel alto, medio y bajo, más que trayectorias opuestas entre elecciones.

4.2. Caracterización de los perfiles

Cuadro 4: Resumen de los cuatro perfiles ciudadanos

Perfil	Unidades	%	Promedio	Rasgos principales
Participación históricamente alta	623	24.96	71.67 %	Mayor presencia de mujeres, edades mayores y secciones rurales.
Participación históricamente media-alta	835	33.45	61.26 %	Composición más equilibrada; mayor presencia de edades medias.
Participación históricamente media-baja	676	27.08	50.32 %	Ligera mayoría masculina y mayor presencia urbana.
Participación históricamente baja	362	14.50	38.59 %	Predominio masculino y concentración en edades jóvenes.

Cuadro 5: Trayectoria promedio de participación de los cuatro perfiles %

Perfil	2009	2012	2015	2018	2021	2024
Alta	61.69	76.65	68.37	76.49	71.09	75.71
Media-alta	51.99	68.19	56.12	66.87	59.52	64.90
Media-baja	40.42	58.00	43.77	57.55	48.05	54.12
Baja	29.53	46.74	31.77	46.56	35.59	41.38

4.3. Perfil 1: Participación históricamente alta

Reúne 623 unidades (24.96 %) y tiene un promedio histórico de 71.67 %. Su trayectoria fue 61.69 % en 2009, 76.65 % en 2012, 68.37 % en 2015, 76.49 % en 2018, 71.09 % en 2021 y 75.71 % en 2024. El 62.6 % de sus unidades corresponde a mujeres, 48.6 % a secciones rurales y el grupo de edad con mayor presencia es 65–69 años (20.1 %). Yucatán y Campeche presentan una presencia relativa destacada de este perfil. En conjunto, el perfil representa unidades que permanecen sistemáticamente por encima del resto de la distribución, aun cuando el nivel general de participación cambia de una elección a otra.

4.4. Perfil 2: Participación históricamente media-alta

Es el grupo de mayor tamaño, con 835 unidades (33.45 %) y promedio histórico de 61.26 %. Presenta ligera mayoría de mujeres (55.2 %) y una composición territorial equilibrada: 35.8 % mixta, 34.7 % urbana y 29.5 % rural. Las edades con mayor presencia se concentran entre 45 y 59 años. Jalisco y Zacatecas destacan por la presencia relativa de este perfil. Su rasgo principal es la estabilidad en un nivel intermedio-alto, con una composición menos concentrada que la del perfil de participación alta.

4.5. Perfil 3: Participación históricamente media-baja

Agrupa 676 unidades (27.08 %) y tiene un promedio histórico de 50.32 %. El 52.5 % de sus unidades corresponde a hombres. Las secciones urbanas representan 36.8 %, las mixtas 34.0 % y las rurales 29.1 %. Su estructura por edad es más heterogénea, con presencia relevante de 75+, 18–19, 35–39 y 30–34 años. Baja California y Chihuahua tienen una presencia relativa destacada. Este perfil presenta niveles de participación medios-bajos y una composición demográfica heterogénea, sin un grupo de edad claramente dominante.

4.6. Perfil 4: Participación históricamente baja

Incluye 362 unidades (14.50 %) y presenta el menor promedio histórico, 38.59 %. El 79.0 % de las unidades corresponde a hombres y existe una concentración marcada en 20–34 años: 29.0 % en 25–29, 27.6 % en 20–24 y 18.5 % en 30–34. Las secciones mixtas y urbanas representan aproximadamente 38.1 % cada una. Baja California y Chihuahua muestran una presencia relativa importante. La concentración masculina y en edades de 20 a 34 años constituye la diferencia sociodemográfica más marcada entre los cuatro perfiles.

Estas asociaciones describen unidades agregadas y no deben interpretarse como determinantes individuales del comportamiento electoral.

5. Estrategias diferenciadas

Las propuestas se plantean desde una perspectiva institucional, neutral y no partidista. Su objetivo es mejorar el acceso a información electoral oficial y reducir barreras prácticas, no orientar preferencias políticas.

Cuadro 6: Estrategias propuestas por perfil

Perfil	Necesidad principal	Acciones institucionales sugeridas
Alta	Mantener accesibilidad y continuidad informativa	Recordatorios de fechas y ubicación de casillas; formatos impresos y digitales; orientación logística y materiales accesibles para población de mayor edad y localidades rurales.
Media-alta	Reducir pequeñas barreras prácticas	Información oportuna de casillas y requisitos; mensajes breves; herramientas oficiales de consulta y combinación de canales digitales y territoriales.
Media-baja	Simplificar el proceso y facilitar la consulta	Guías paso a paso; localizador de casilla; contenidos prácticos en formatos digitales, impresos y presenciales; énfasis en información verificable.
Baja	Mejorar acceso a información clara para adultos jóvenes	Información oficial breve, visual y móvil; difusión informativa en espacios educativos, laborales y comunitarios; explicación sencilla de cuándo, dónde y cómo participar.

La evaluación de estas acciones puede apoyarse en consultas a herramientas institucionales, uso de localizadores de casilla, alcance de materiales y mediciones de comprensión de información electoral. También pueden establecerse indicadores previos y posteriores de conocimiento sobre fechas, requisitos y ubicación de casillas para valorar si la información llegó a los grupos previstos. Las variaciones posteriores de participación deben interpretarse con cautela y no atribuirse causalmente a una estrategia sin un diseño de evaluación adecuado.

6. Discusión e implicaciones de los perfiles

Los cuatro perfiles obtenidos permiten resumir una estructura compleja de participación electoral sin reducir el análisis a una sola elección. El principal hallazgo es que las diferencias entre grupos no aparecen únicamente en un proceso aislado, sino que mantienen una separación relativamente consistente a lo largo de la serie 2009–2024. Aunque todas las trayectorias responden a cambios generales entre elecciones, los conglomerados conservan un orden semejante: las unidades clasificadas en el perfil alto permanecen, en promedio, por encima de las demás, mientras que las del perfil bajo se mantienen en los niveles inferiores. Esta persistencia es coherente con las correlaciones positivas observadas entre las seis elecciones y explica por qué el algoritmo produjo perfiles diferenciados principalmente por nivel histórico de participación.

La utilidad de esta segmentación no consiste en asignar una etiqueta fija a cada persona, sino en identificar combinaciones agregadas que presentan necesidades distintas de información y accesibilidad electoral. Por ejemplo, el perfil de participación históricamente alta concentra una mayor proporción de unidades de mujeres, edades mayores y secciones rurales; en contraste, el perfil bajo presenta una fuerte concentración de unidades masculinas y de edades entre 20 y 34 años. Estas diferencias permiten formular hipótesis de trabajo sobre los formatos, canales y tipos de información que podrían ser más útiles para cada conjunto, sin asumir que una característica sociodemográfica determine por sí misma la conducta electoral.

También es relevante que los perfiles intermedios representen la mayor parte de la base comparable. En conjunto, los perfiles media-alta y media-baja reúnen más de la mitad de las unidades analizadas. Esto muestra que la segmentación no divide únicamente entre “quienes participan” y “quienes no participan”, sino que identifica niveles intermedios con composiciones diferentes. En términos operativos, esta distinción permite evitar estrategias uniformes y reconocer que las necesidades de información pueden variar incluso entre grupos que no se encuentran en los extremos de participación.

Desde una perspectiva institucional, los perfiles pueden utilizarse como una herramienta de priorización para diseñar materiales informativos, seleccionar formatos de difusión y decidir dónde conviene reforzar servicios de consulta. Su uso debe mantenerse en un marco ge-

neral y transparente. La información agregada puede orientar, por ejemplo, el desarrollo de materiales accesibles para personas de mayor edad, herramientas móviles de consulta para población joven adulta o combinaciones de canales digitales y territoriales en zonas donde una sola vía de comunicación podría resultar insuficiente. En todos los casos, el contenido debe permanecer centrado en información oficial sobre fechas, requisitos, ubicación de casillas y procedimientos, sin buscar orientar preferencias políticas.

Los resultados también sugieren que la evaluación de las estrategias debe considerar indicadores distintos de la participación final. Un aumento o disminución en la tasa de votación puede depender de numerosos factores externos y no puede atribuirse automáticamente a una acción informativa. Por ello, resulta más apropiado medir primero variables directamente relacionadas con la intervención, como consultas al localizador de casillas, alcance de materiales, comprensión de requisitos, conocimiento de fechas o facilidad percibida para encontrar información oficial. Solo posteriormente, y con un diseño de evaluación adecuado, podría estudiarse la relación entre estas acciones y cambios agregados de participación.

Finalmente, la segmentación puede actualizarse cuando se incorporen nuevos procesos electorales. La estructura propuesta es reproducible: parte de una unidad de análisis explícita, utiliza las mismas reglas de homologación y permite volver a estimar los conglomerados con información adicional. Esto evita tratar los perfiles como categorías permanentes. Su valor radica en funcionar como una fotografía analítica de los patrones disponibles hasta 2024 y como una base para futuras comparaciones, revisiones y ajustes metodológicos.

7. Limitaciones

El estudio utiliza información agregada, por lo que los perfiles representan patrones de unidades y no trayectorias individuales. En consecuencia, no debe inferirse que todas las personas que comparten edad, sexo, entidad o tipo de sección se comportan de la misma manera.

La comparabilidad histórica también está condicionada por la disponibilidad de categorías entre elecciones. La segmentación principal utiliza las 2,496 unidades con información completa en los seis procesos; las 50 unidades no binarias observadas en 2024 se conservaron en la base maestra, pero no se les imputó información previa. Asimismo, el umbral de 100 registros determinados se usó solamente para sensibilidad y no como regla oficial.

Finalmente, K-means es una técnica exploratoria y sus resultados dependen de las variables, la estandarización y el número de conglomerados evaluados [4]. La silueta obtenida indica separación moderada, por lo que los perfiles deben entenderse como una síntesis útil de patrones históricos, no como categorías absolutas.

8. Conclusiones

La metodología permitió integrar seis procesos electorales de forma reproducible y construir cuatro perfiles claramente diferenciados. La solución $k = 4$ presentó la mayor silueta entre las alternativas permitidas y se mantuvo estable ante la exclusión de grupos pequeños. Los resultados muestran persistencia histórica en los niveles relativos de participación: el perfil alto concentra mayor presencia de mujeres, edades mayores y secciones rurales, mientras que el perfil bajo presenta mayor presencia de hombres y edades jóvenes. Los perfiles intermedios muestran composiciones más equilibradas.

Los perfiles se proponen como una herramienta descriptiva para identificar necesidades diferenciadas de información y accesibilidad electoral. Su utilidad principal consiste en orientar acciones institucionales generales y evaluables, manteniendo un enfoque neutral y no partidista. La propuesta complementa las fichas visuales del reto y proporciona una ruta reproducible desde los datos originales hasta la caracterización final de los perfiles.

Referencias

[1] Instituto Nacional Electoral. *Conteos Censales de Participación Ciudadana*. INE, consulta pública en línea. Disponible en: https://www.ine.mx/transparencia/datos-abiertos/visualizacion-datos/conteos-censales-participacion/

[2] Instituto Nacional Electoral. *Conteos Censales de Participación Ciudadana 2009–2024: Manual de uso de la plataforma para el análisis y la consulta*. INE, 2025. Disponible en: https://www.ine.mx/wp-content/uploads/2025/06/Manual-Conteos-Censales-2009-2024.pdf

[3] Instituto Nacional Electoral. *Hackathon 2026: Hackea la participación, Datos que construyen democracia*. INE, 2026. Disponible en: https://www.ine.mx/hackathon-2026/

[4] Universidad Nacional de Educación a Distancia. *Análisis de conglomerados*. UNED, recurso educativo de consulta pública. Disponible en: https://www.uned.es/universidad/inicio/estudios/formacion-permanente/cursos/experto-metodos-avanzados/programa/conglomerados.html

[5] Jiménez García, M.; Gómez Miranda, P.; Romero García, J. A.; y Jiménez Jiménez, R. S. “Acceso a tecnologías en el rendimiento universitario en tiempos del COVID-19: análisis de asociación por clústeres”. *RIDE*, vol. 13, núm. 26, 2023. Disponible en: https://www.scielo.org.mx/scielo.php?pid=S2007-74672023000100122&script=sci_arttext